UNIVERSIDAD NACIONAL DEL CENTRO DEL PERÚ

FACULTAD DE INGENIERÍA DE SISTEMAS

Rúbrica de Evaluación

Proyecto de evaluación parcial: del dato al asistente

Asignatura	Tecnologías Emergentes (ISO46B)
Escala	Vigesimal (0–20)
Composición	Parte grupal 16 puntos + defensa individual 4 puntos
Niveles	Insuficiente · En proceso · Logrado · Destacado

1. Cómo se calcula la nota

Nota final de un estudiante = (Puntaje grupal C1–C8 × Factor de contribución) + Puntaje de defensa individual.

- Puntaje grupal: suma de C1 a C8 (máximo 16,0). Lo asigna el docente al sistema entregado y a la presentación.
- Factor de contribución (FC): entre 0,50 y 1,00 para cada integrante. Se define con tres fuentes: historial de commits, coevaluación entre integrantes (hoja del anexo B) y lo observado en la defensa. Por defecto, FC = 1,00.
- Defensa individual: D1 y D2 (máximo 4,0), preguntas directas a cada integrante.
- Redondeo: la nota final se redondea al entero más cercano según el reglamento de la asignatura; 0,5 sube.

2. Rúbrica de la parte grupal

C1. Planteamiento y ética — máximo 1,0 puntos

Nivel	Puntos	Descriptor
Insuficiente	0–0,3	El problema es vago o copiado del dataset. No hay usuario ni decisión definidos. Sin reflexión ética.
En proceso	0,4–0,6	Define problema y usuario, pero no la métrica ni el costo de los errores. La ética se menciona sin análisis.
Logrado	0,7–0,8	Problema, usuario, decisión, error más costoso y métrica coherentes. Identifica al menos un riesgo ético propio de su dataset.
Destacado	0,9–1,0	Además declara el momento de la predicción y qué variables estarían disponibles; propone medidas concretas para el riesgo ético (exclusión, auditoría, derivación humana).

C2. Datos y exploración (sin fuga) — máximo 2,5 puntos

Nivel	Puntos	Descriptor
Insuficiente	0–0,9	Los datos no se cargan o se limpian sin criterio. El preprocesamiento se ajusta con todos los datos (fuga).
En proceso	1,0–1,7	Carga y limpia lo evidente pero no detecta los problemas propios del dataset; la partición es correcta pero sin estratificar o sin semilla.
Logrado	1,8–2,2	Detecta y resuelve los problemas de calidad, hace un EDA con hallazgos interpretados y particiona (estratificado, con semilla) ajustando el preprocesamiento solo con entrenamiento.
Destacado	2,3–2,5	Además documenta cada decisión de limpieza con su justificación, detecta variables que filtran el futuro o duplicados que contaminarían la prueba, y lo comprueba con pruebas automáticas.

C3. Modelado y comparación — máximo 2,5 puntos

Nivel	Puntos	Descriptor
Insuficiente	0–0,9	Entrena un solo modelo, sin línea base, o el modelo no se entrena correctamente.
En proceso	1,0–1,7	Hay línea base y un modelo de red neuronal, pero la comparación es solo de una métrica o sin criterio.
Logrado	1,8–2,2	Línea base trivial y simple, y al menos dos versiones de red neuronal con configuraciones justificadas (regularización, parada temprana, pesos de clase si aplica). Compara con las mismas métricas.
Destacado	2,3–2,5	Además concluye con honestidad si la red mejora o no a la línea base, distingue diferencias reales de ruido y reporta la variabilidad (semillas o validación cruzada).

C4. Evaluación y versionado — máximo 2,5 puntos

Nivel	Puntos	Descriptor
Insuficiente	0–0,9	Evalúa solo con accuracy o decide mirando la prueba.
En proceso	1,0–1,7	Usa varias métricas, pero elige el modelo sin un criterio explícito o no guarda versiones completas.
Logrado	1,8–2,2	Métricas adecuadas al problema, versión ganadora elegida solo con validación, evaluación única en prueba, ficha JSON por versión y versión promovida identificable.
Destacado	2,3–2,5	Además ajusta el umbral o la regla de decisión según el costo de errores, analiza los errores (matriz de confusión, por grupo o por clase) y deja trazabilidad completa (datos, parámetros, fecha, métricas).

C5. API — máximo 2,0 puntos

Nivel	Puntos	Descriptor
Insuficiente	0–0,7	La API no arranca o no devuelve predicciones.
En proceso	0,8–1,3	Responde a solicitudes correctas, pero no valida entradas o los errores no son claros.
Logrado	1,4–1,7	Carga la versión promovida, valida entradas, devuelve 400 con mensajes comprensibles y expone /salud. Devuelve predicción, probabilidad y versión.
Destacado	1,8–2,0	Además está cubierta por pruebas (caso exitoso y casos de error), documenta el contrato de entrada y salida y mide su latencia.

C6. Chatbot — máximo 2,5 puntos

Nivel	Puntos	Descriptor
Insuficiente	0–0,9	El chatbot no se conecta con la API o repite la entrada sin conversación.
En proceso	1,0–1,7	Recolecta datos y consulta la API, pero se rompe ante respuestas inesperadas o no tiene derivación.
Logrado	1,8–2,2	Flujo con camino feliz, alternativos y de error; recolección por pasos con validación; fallback con límite de reintentos; derivación a una persona; lenguaje adecuado para un usuario no técnico. Incluye el diagrama.
Destacado	2,3–2,5	Además adapta su respuesta al resultado (recomendaciones), cuida la privacidad, reconoce sus propias limitaciones y las demuestra con pruebas automáticas de conversación.

C7. Calidad y reproducibilidad — máximo 1,0 puntos

Nivel	Puntos	Descriptor
Insuficiente	0–0,3	No se puede ejecutar siguiendo el README o no hay pruebas.
En proceso	0,4–0,6	Se ejecuta con ayuda del equipo; las pruebas cubren solo el caso exitoso.
Logrado	0,7–0,8	Se ejecuta desde cero siguiendo el README; hay requirements.txt y pytest en verde con casos de éxito y de error.
Destacado	0,9–1,0	Además las pruebas cubren datos, API y chatbot, los resultados se reproducen con la misma semilla y el código está ordenado y comentado donde importa.

C8. Informe y presentación — máximo 2,0 puntos

Nivel	Puntos	Descriptor
Insuficiente	0–0,7	El informe es una lista de código y salidas sin explicación; la presentación no sigue un hilo.
En proceso	0,8–1,3	El informe describe lo hecho pero no justifica decisiones; la demostración tiene fallos no previstos.
Logrado	1,4–1,7	Informe claro con secciones 1 a 8, figuras legibles y decisiones justificadas; presentación en el tiempo y demostración exitosa con un caso de error.
Destacado	1,8–2,0	Además comunica limitaciones y próximos pasos con franqueza, usa figuras que sostienen el argumento y resuelve con seguridad las preguntas del público.

3. Rúbrica de la defensa individual

D1. Dominio conceptual — máximo 2,0 puntos

Nivel	Puntos	Descriptor
Insuficiente	0–0,7	No puede explicar términos básicos de su proyecto (fuga, validación vs. prueba, umbral, versión).
En proceso	0,8–1,3	Explica los conceptos de forma memorizada y no los conecta con su proyecto.
Logrado	1,4–1,7	Explica los conceptos y los aplica a su proyecto con ejemplos propios.
Destacado	1,8–2,0	Además razona ante preguntas nuevas («¿qué pasaría si…?») y reconoce con precisión los límites de su solución.

D2. Dominio del código propio y ajeno — máximo 2,0 puntos

Nivel	Puntos	Descriptor
Insuficiente	0–0,7	No reconoce el código ni puede ubicar una función en el repositorio.
En proceso	0,8–1,3	Entiende su propia parte pero no la del resto del grupo.
Logrado	1,4–1,7	Explica su parte y la visión general; ubica rápido las funciones y hace un cambio pequeño si se le pide.
Destacado	1,8–2,0	Además anticipa el efecto de un cambio en otra etapa (por ejemplo, qué se rompe en la API si cambia una columna) y lo demuestra.

Anexo A. Hoja de evaluación de la defensa

Grupo / Dataset	
Fecha y hora	
Evaluador	Ing. Jaime Huaytalla Pariona

Criterio grupal	Máx.	Nivel (I / P / L / D)	Puntaje	Observaciones
C1. Planteamiento y ética	1,0			
C2. Datos y exploración (sin fuga)	2,5			
C3. Modelado y comparación	2,5			
C4. Evaluación y versionado	2,5			
C5. API	2,0			
C6. Chatbot	2,5			
C7. Calidad y reproducibilidad	1,0			
C8. Informe y presentación	2,0			

Integrante	FC (0,50–1,00)	D1 (máx. 2,0)	D2 (máx. 2,0)	Nota final
1.				
2.				
3.				
4.				

Fórmula: Nota = (Σ C1…C8 × FC) + D1 + D2.

Anexo B. Banco de preguntas para la defensa individual

Elija 2 por integrante; siempre una de una parte que esa persona no desarrolló.

Etapa	Pregunta	Qué se busca
E1	¿Qué error le cuesta más a quien usaría su sistema: el falso positivo o el falso negativo? ¿Cómo se refleja en su métrica?	Vincula la métrica con el costo real
E1	¿En qué momento exacto se haría la predicción y qué datos tendría en ese momento?	Detección de fuga conceptual
E2	¿Qué problema de calidad encontraron en los datos y qué decidieron hacer? ¿Qué habría pasado si no lo hacían?	Hallazgos propios, no genéricos
E2	Si escalan los datos antes de dividir, ¿qué problema se genera? Muéstrenme en el código dónde evitan eso.	Fuga por preprocesamiento
E2	¿Por qué estratificaron la partición?	Clases desbalanceadas
E3	Su línea base trivial obtiene X de exactitud. ¿Por qué esa cifra no sirve para presumir su modelo?	Accuracy vs. desbalance
E3	¿Qué hace el early stopping y qué pasaría si lo quitan? ¿Y el dropout?	Regularización
E3	Su red no supera a la regresión logística. ¿Qué concluyen? ¿Cambiarían de modelo?	Honestidad intelectual
E4	¿Con qué conjunto eligieron el modelo y con cuál lo evaluaron al final? ¿Por qué no se mira la prueba antes?	Validación vs. prueba
E4	Si la prueba favoreciera al otro modelo, ¿cambiarían la elección? ¿Por qué?	Disciplina del procedimiento
E4	¿Cómo eligieron el umbral (o la regla de decisión en multiclase)? ¿Qué cambiaría si el costo de un error se duplica?	Decisión basada en costo
E4	Abran la ficha JSON de su versión promovida: ¿qué sirve para reproducir ese resultado?	Trazabilidad
E5	¿Qué ocurre si envían un campo faltante, un texto donde va un número o un valor fuera de rango? Demuéstrenlo.	Validación

Etapa	Pregunta	Qué se busca
E5	¿Por qué la API carga el modelo al arrancar y no en cada solicitud?	Eficiencia
E5	Si mañana se entrena una nueva versión, ¿qué cambia en la API y qué no?	Versionado y despliegue
E6	Muéstrenme un caso en que el chatbot no entiende. ¿Qué hace? ¿Cuántas veces insiste antes de derivar?	Fallback y derivación
E6	¿Qué información sensible podría escribir el usuario y qué hace el chatbot con ella?	Privacidad
E6	¿Qué ganarían y qué riesgos tendrían si reemplazaran el chatbot de reglas por un modelo de lenguaje?	Comparación de arquitecturas
E7	Borren una columna de la entrada y corran las pruebas: ¿cuál falla primero y por qué?	Pruebas con sentido
Ética	¿El error de su modelo es igual para todos los grupos de personas? ¿Cómo lo comprobaron?	Equidad